Comparativo entre as Abordagens ETL e ELT

Integração de dados epidemiológicos de Zika (2024–2026)

1 Introdução

O objetivo desse documento é apresentar, de maneira comparativa, o uso das estratégias de integração ETL e ELT nos conjuntos de dados de Zika Vírus nos anos 2024, 2025 e 2026. Antes da execução das etapas de transformação, foram feitas análises nos conjuntos de dados com o intuito de identificar inconsistências que poderiam comprometer a integração dos dados. Essa etapa é importante, tendo em vista que dados indevidamente tratados podem causar problemas de interpretação e inferência posteriores. Embora ambas as estratégias devam aplicar regras equivalentes de padronização, as abordagens diferem quanto à ordem e ao ambiente de execução das transformações. Na abordagem ETL deste projeto, as tecnologias escolhidas para a extração e a transformação dos dados foram a linguagem Python e a biblioteca Pandas, antes da carga no banco de destino. No ELT, os registros são inicialmente carregados em uma camada de preparação, e as transformações são executadas posteriormente no SGBD. Informações como tempo de execução de cada pipeline, integridade dos dados, escalabilidade, complexidade de implementação e consumo de recursos computacionais serão levadas em consideração nesta análise.

2 Implementação das abordagens

2.1 Pipeline ETL

2.1.1 Extração e Consolidação Inicial

Inicialmente os conjuntos de dados referentes aos anos de 2024, 2025 e 2026 foram carregados individualmente, pelo uso da biblioteca Pandas. Em seguida, os 3 dataframes foram concatenados em um só conjunto consolidado. Entretanto, essa consolidação não garante que os dados estejam totalmente organizados, isto é, livres de duplicatas e/ou outros ruídos. A limpeza e a padronização serão realizadas nas etapas seguintes.

2.1.2 Transformação e Higienização (Transform – T1)

Aplicação sequencial das 6 regras de limpeza e padronização de negócio:

1. **Padronização de `ID_AGRAVO`:**
   Unificação de `A92.` (5.427 registros de 2024) para `A928`.
2. **Higienização de `COUFINF`:**
   Conversão da sigla textual `ES` para o código IBGE 32 e substituição de 0 falso por `NaN`.
3. **Eliminação de Zeros Falsos (0 → NaN):**
   Conversão do preenchimento 0 (inexistente no dicionário SINAN)
   para `NaN` em
   `CLASSI_FIN`, `CRITERIO`, `EVOLUCAO`,
   `ID_RG_RESI`, `NDUPLIC_N`,
   `IN_VINCULA`, `ID_OCUPA_N`,
   `COMUNINF`, `DOENCA_TRA`,
   `TP_SISTEMA`, `TPUNINOT`
   e `COPAISINF`
   (preservando 0 = Analfabeto em `CS_ESCOL_N`).
4. **Decodificação da Idade (`NU_IDADE_N`):**
   Conversão do código composto de 4 dígitos (1xxx = Horas, 2xxx = Dias, 3xxx = Meses, 4xxx = Anos)
   para `idade_anos` e categorização em `faixa_etaria`.
5. **Saneamento de Datas e Cálculo de Métricas Temporais:**
   Conversão para `datetime`, cálculo de `qt_dias_atraso_notif` (`DT_NOTIFIC` - `DT_SIN_PRI`)
   e `qt_dias_encerramento` (`DT_ENCERRA` - `DT_NOTIFIC`),
   expurgando os 73 registros com intervalos negativos (< 0 dias, como -674) ou superiores a 1 ano (> 365 dias).
6. **Enriquecimento Semântico e Flags Analíticas:**
   Mapeamento de códigos IBGE de UF para siglas e regiões
   do Brasil, tradução dos domínios numéricos (`ds_sexo`, `ds_raca_cor`,
   `ds_gestante`, `ds_escolaridade`,
   `ds_classificacao_final`,
   `ds_criterio_confirmacao`,
   `ds_evolucao_caso`)
   e criação das flags binárias (`fl_confirmado`, `fl_descartado`,
   `fl_gestante`, `fl_obito`,
   `fl_autoctone`).

2.1.3 Modelagem Dimensional e Carga

A partir do DataFrame `df_zika_limpo` (Parte 1), esta seção constrói as 5 dimensões com surrogate keys, monta a tabela fato `fato_notificacao_z`

ika e carrega o Esquema Estrela em um banco MySQL, comprovando o resultado com consultas SQL.

O banco é criado executando o DDL do repositório (sql/01_script_ddl_do_esquema_estrela.sql), que define as PKs, FKs e os registros Não Informado (SK = 0). Em seguida, o to_sql(if_exists='append') carrega as 5 dimensões e a fato na ordem correta de dependência (dimensões primeiro). O MySQL precisa ser instalado no colab para ser utilizado. Abaixo se encontra as 5 dimensões.

2.1.4 Validação dos Dados

A etapa de validação dos dados será realizada por meio de consultas SQL, com o objetivo de verificar a consistência das informações após a carga do banco de dados. Serão realizadas verificações de integridade referencial, contagens de registros e comparações entre os resultados alcançados

2.2 Pipeline ELT

2.2.1 Extração e Carga dos Dados Brutos

Na implementação do ELT, foram utilizados os mesmos conjuntos de dados vistos no ETL. No entanto, a abordagem dessa vez é diferente da anterior, pois dessa vez os dados são carregados antes do tratamento. Ou seja, a transformação é feita utilizando comandos do SQL no próprio SGBD. Para isso utiliza-se uma tabela intermediária de preparação, denominada stg_zika responsável por armazenar os registros provenientes dos arquivos CSV.

2.2.2 Validação, Controle de Qualidade e Quarentena

Após o carregamento dos dados, o pipeline inicia a etapa denominada quality gate. Essa etapa tem como objetivo identificar inconsistências antes de sua utilização na construção do modelo dimensional. As verificações são feitas com o uso de comandos SQL no próprio MySQL que avaliam os dados em questão com critérios de qualidade estabelecidos. A partir dessas verificações, os dados são classificados quanto a sua qualidade para prosseguir nas etapas de transformação. Os registros que não atenderem aos critérios estabelecidos entram em um mecanismo chamado quarentena. Desse modo, permite-se que informações inconsistentes não sejam incorporados às dimensões e à tabela fato.

2.2.3 Transformação e Construção das Dimensões

As dimensões são populadas por meio de instruções SQL INSERT INTO ... SELECT ... ON DUPLICATE KEY UPDATE, que permitem inserir novos registros ou atualizar os existentes em caso de conflito de chave, favorecendo a idempotência da operação. Além disso, cada arquivo é processado separadamente, visando preservar o controle transacional e a rastreabilidade dos registros de origem. Entre as transformações realizadas estão a conversão de datas e a criação de atributos temporais, o cálculo das semanas epidemiológicas, a padronização das informações geográficas e a decodificação dos atributos demográficos além da normalização da dimensão agravo. A organização ocorre em 5 dimensões: dim_tempo, dim_semana_epidemiologica, dim_geografia, dim_paciente, dim_agravo. A combinação dessas dimensões foi criada para uma melhor inferência a respeito da análise epidemiológica

2.2.4 Construção e Carga da Tabela Fato

Depois do carregamento das dimensões, é feito o preenchimento da tabela fato com os registros que passaram pelo controle de qualidade. Cada linha agora significa um registro de zika e contém chaves que permitem recuperar informações nas dimensões de tempo, semana, geografia, paciente e agravo. Nessa etapa também são encontradas medidas derivadas, como dias_sintomas_notificacao que representa a quantidade de dias que se passaram entre o início dos sintomas e a notificação; duplicado_exato que diz respeito aos registros repetidos e notificado_em_7_dias que informa se a notificação ocorreu em até 7 dias.

2.2.5 Validação dos Dados e Auditoria

Essa etapa busca avaliar a consistência dos dados armazenados em relação à sua qualidade, por meio da execução do pipeline. Foi feita em 3 categorias: A primeira se refere a integridade estrutural, que contempla a verificação das chaves primárias e estrangeiras e identificação de registros duplicados. A segunda verifica se os dados epidemiológicos apresentam valores coerentes. A terceira tem o intuito de verificar se os valores armazenados fazem sentido de acordo com os dados epidemiológicos. No final de tudo os dados são reunidos em um scorecard onde serão detectados alertas e falhas na validação do pipeline O resultado é um scorecard com status OK, ALERTA ou FALHA. Falhas críticas interrompem o pipeline; alertas são registrados.

Tabela 1: Dimensões do Esquema Estrela e suas responsabilidades

Dimensão	Responsabilidade
`dim_tempo`	Armazenar informações temporais relacionadas às notificações e ao início dos sintomas.
`dim_localidade`	Organizar informações geográficas, permitindo análises por município, estado e região.
`dim_unidade_notificadora`	Armazenar informações referentes às unidades responsáveis pelas notificações.
`dim_paciente`	Organizar características dos pacientes, como sexo, faixa etária, raça/cor e escolaridade.
`dim_investigacao_desfecho`	Armazenar informações relacionadas à investigação, classificação final e evolução dos casos.

3 Metodologia comparativa

3.1 Procedimento Experimental

Para realizar a comparação entre os pipelines ETL e ELT, serão utilizados os mesmo conjuntos de dados de Zika 2024, 2025 e 2026. Ambos serão executados no ambiente Colab, mantendo o MySQL como sistema de gerenciamento de banco de dados. Antes de cada execução, o banco de dados será preparado para evitar que registros anteriores possam interferir nos resultados. As medições considerarão as principais etapas de cada abordagem, desde a leitura dos arquivos até a disponibilização dos dados nas tabelas do modelo dimensional. Por meio disso será possível encontrar o tempo necessário para processar cada conjunto de dados e compará-los.

3.2 Métricas de avaliação

As métricas e os critérios considerados para a comparação entre os pipelines ETL e ELT serão:

- **Tempo de execução:**
  duração total e das principais etapas;
- **Consumo de memória:**
  consumo máximo durante o processamento;
- **Integridade dos dados:**
  contagens, chaves estrangeiras e consistência;
- **Escalabilidade:**
  comportamento com diferentes volumes de dados;
- **Complexidade:**
  etapas, dependências e manutenção.

3.3 Critérios de Comparação e Limitações

A comparação feita a seguir levará em consideração que os dados foram transformados e organizados usando algumas regras diferentes.

A implementação do ELT, quando comparado com o ETL, apresenta dimensões adicionais criadas com o objetivo de ampliar as possibilidades de análise dos dados. Essa decisão pode aumentar a quantidade de operações a serem realizadas e consequentemente incluenciar o desempenho. A comparação de integridade deverá considerar não apenas os valores obtidos, mas também os critérios utilizados por cada pipeline, tendo em vista que a quantidade final de dados nas tabelas pode ser distinta devido a maneira como ocorreu cada uma das regras, como a limpeza. Desse modo, os resultados serão interpretados levando em consideração essas particularidades, evitando atribuir exclusivamente, evitando atribuir exclusivamente à escolha entre ETL e ELT diferenças que também possam decorrer das decisões de implementação.

4 Resultados e discussões

5 Conclusão

Tabela 2: Matriz de equivalência das transformações ETL e ELT

Campo	**ETL (Pandas)**	**ELT (SQL)**	**Verificação**
`ID_AGRAVO`	Padronização de códigos	Normalização na dimensão de agravo	Comparar os códigos resultantes.
`COUFINF`	Tratamento dos códigos de UF e de zeros inválidos	Tratamento dos atributos geográficos	Comparar os valores de UF.
`NU_IDADE_N`	Decodificação e categorização da idade	Decodificação na dimensão paciente	Comparar as idades e faixas etárias.
`DT_NOTIFIC`	Conversão dos valores para datas	Conversão e derivação de atributos temporais	Verificar datas inválidas e valores resultantes.
`CLASSI_FIN`	Tratamento e criação de indicadores	Tratamento da classificação dos casos	Comparar as categorias e os indicadores.
`EVOLUCAO`	Tratamento dos valores e criação do indicador de óbito	Tratamento da evolução dos casos	Comparar os critérios utilizados e os indicadores.