1 Introdução

O objetivo desse documento é apresentar, de maneira comparativa, o uso das estratégias de integração ETL e ELT nos conjuntos de dados de Zika Vírus nos anos 2024, 2025 e 2026.

Antes da execução das etapas de transformação, foram feitas análises nos conjuntos de dados com o intuito de identificar inconsistências que poderiam comprometer a integração dos dados. Essa etapa é importante, tendo em vista que dados indevidamente tratados podem causar problemas de interpretação e inferência posteriores.

Embora ambas as estratégias devam aplicar regras equivalentes de padronização, as abordagens diferem quanto à ordem e ao ambiente de execução das transformações. Na abordagem ETL deste projeto, as tecnologias escolhidas para a extração e a transformação dos dados foram a linguagem Python e a biblioteca Pandas, antes da carga no banco de destino. No ELT, os registros são inicialmente carregados em uma camada de preparação, e as transformações são executadas posteriormente no SGBD.

Informações como tempo de execução de cada pipeline, integridade dos dados, escalabilidade, complexidade de implementação e consumo de recursos computacionais serão levadas em consideração nesta análise.

2 Implementação das abordagens

2.1 Pipeline ETL

2.1.1 Extração e Consolidação Inicial

Inicialmente os conjuntos de dados referentes aos anos de 2024, 2025 e 2026 foram carregados individualmente, pelo uso da biblioteca Pandas. Em seguida, os 3 dataframes foram concatenados em um só conjunto consolidado. Entretanto, essa consolidação não garante que os dados estejam totalmente organizados, isto é, livres de duplicatas e/ou outros ruídos. A limpeza e a padronização serão realizadas nas etapas seguintes.

2.1.2 Transformação e Higienização (Transform – T1)

Aplicação sequencial das 6 regras de limpeza e padronização de negócio:

1. **Padronização de `ID_AGRAVO`:** Unificação de `A92.` (5.427 registros de 2024) para `A928`.

2. **Higienização de `COUFINF`:** Conversão da sigla textual `ES` para o código IBGE 32 e substituição de 0 falso por `NaN`.

3. **Eliminação de Zeros Falsos (0 → NaN):** Conversão do preenchimento 0 (inexistente no dicionário SINAN) para `NaN` em `CLASSI_FIN`, `CRITERIO`, `EVOLUCAO`, `ID_RG_RESI`, `NDUPLIC_N`, `IN_VINCULA`, `ID_OCUPA_N`, `COMUNINF`, `DOENCA_TRA`, `TP_SISTEMA`, `TPUNINOT` e `COPAISINF` (preservando 0 = Analfabeto em `CS_ESCOL_N`).

4. **Decodificação da Idade (`NU_IDADE_N`):** Conversão do código composto de 4 dígitos (1xxx = Horas, 2xxx = Dias, 3xxx = Meses, 4xxx = Anos) para `idade_anos` e categorização em `faixa_etaria`.

5. **Saneamento de Datas e Cálculo de Métricas Temporais:** Conversão para `datetime`, cálculo de `<qt_dias_atraso_notif>` (`<DT_NOTIFIC>` - `<DT_SIN_PRI>`) e `<qt_dias_encerramento>` (`<DT_ENCERRA>` - `<DT_NOTIFIC>`), expurgando os 73 registros com intervalos negativos (< 0 dias, como -674) ou superiores a 1 ano (> 365 dias).

6. **Enriquecimento Semântico e Flags Analíticas:** Mapeamento de códigos IBGE de UF para siglas e regiões do Brasil, tradução dos domínios numéricos (`<ds_sexo>`, `<ds_raca_cor>`, `<ds_gestante>`, `<ds_escolaridade>`, `<ds_classificacao_final>`, `<ds_criterio_confirmacao>`, `<ds_evolucao_caso>`) e criação das flags binárias (`<fl_confirmado>`, `<fl_descartado>`, `<fl_gestante>`, `<fl_obito>`, `<fl_autoctone>`).

3 Metodologia comparativa

Tabela 1: Comparação das transformações ETL e ELT

Campo	**ETL (Pandas)**	**ELT (SQL)**	**Verificação**
`ID_AGRAVO`	Padronização de códigos	Normalização no MySQL	Comparar códigos finais
`NU_IDADE_N`	Decodificação da idade	Decodificação em SQL	Comparar idades calculadas
`DT_NOTIFIC`	Conversão de datas	Conversão em SQL	Verificar datas inválidas
`CLASSI_FIN`	Criação de indicadores	Classificação no banco	Comparar categorias
`EVOLUCAO`	Indicador de óbito	Tratamento da evolução	Comparar definições

4 Resultados e discussões

5 Conclusão